บทที่ 2 การประมวลผลข้อความ
Textual Data Processing

ผู้ช่วยศาสตราจารย์โอภาส วงษ์ทวีทรัพย์
Asst.Prof.Opas Wongtaweesap (Aj'OaT)
ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร
URL:: http://www.facebook.com/OaTCoM **E-mail::** oatcomster@gmail.com

แนวทางการสอนวันนี้

- **Textual** Data in Digital World.
- Natural Language **Processing.**
- Application **Examples.**
- **PyThaiNLP.**

Textual Data

- **Digital Textual Data**
- the **computer needs a way to understand** each of the characters. textual data is represented in the computer.
  - **Human-readable string data** is a representation of **binary**
  - **ASCII** uses 8-bit
  - **Unicode** uses 8 or 16-bit and is flexible for more bits
  - Unicode is for international use
  - Encoding is a technique to reduce memory footprint

Textual Data

- Simple **ASCII** Exercise, ASCII Practice
  - Go to http://www.ascii-code.com
- **Unicode Character Set** for **international use**
  - Go to http://unicode.org/charts/

Dec	Symbol	Binary	Dec	Symbol	Binary
65	A	0100 0001	83	S	0101 0011
66	B	0100 0010	84	T	0101 0100
67	C	0100 0011	85	U	0101 0101
68	D	0100 0100	86	V	0101 0110
69	E	0100 0101	87	W	0101 0111
70	F	0100 0110	88	X	0101 1000
71	G	0100 0111	89	Y	0101 1001
72	H	0100 1000	90	Z	0101 1010
73	I	0100 1001	91	[	0101 1011
74	J	0100 1010	92	\	0101 1100
75	K	0100 1011	93	]	0101 1101
76	L	0100 1100	94	^	0101 1110
77	M	0100 1101	95	_	0101 1111
78	N	0100 1110	96	`	0110 0000
79	O	0100 1111	97	a	0110 0001
80	P	0101 0000	98	b	0110 0010
81	Q	0101 0001	99	c	0110 0011
82	R	0101 0010	100	d	0110 0100

Unicode 14.0 Character Code Charts

SCRIPTS | SYMBOLS & PUNCTUATION | NAME INDEX

Find chart by hex code: Go Help Conventions Terms of Use

Scripts

European Scripts	African Scripts	South Asian Scripts	Indonesia & Oceania Scripts
Armenian	Adlam	Ahom	Balinese
Armenian Ligatures	Bamum	Bengali and Assamese	Batak
Carian	Bamum Supplement	Bhaiksuki	Buginese
Caucasian Albanian	Bassa Vah	Brahmi	Buhid
Cypriot Syllabary	Coptic	Chakma	Hanunoo
Cypro-Minoan	Coptic in Greek block	Devanagari	Javanese
Cyrillic	Coptic Epact Numbers	Devanagari Extended	Makasar
Cyrillic Supplement	Egyptian Hieroglyphs (1MB)	Dives Akuru	Rejang
Cyrillic Extended-A	Egyptian Hieroglyph Format Controls	Dogra	Sundanese
Cyrillic Extended-B	Ethiopic	Grantha	Sundanese Supplement
Cyrillic Extended-C	Ethiopic Supplement	Gujarati	Tagalog
Elbasan	Ethiopic Extended	Gunjala Gondi	Tagbanwa
Georgian	Ethiopic Extended-A	Gurmukhi	**East Asian Scripts**
Georgian Extended	Ethiopic Extended-B	Kaithi	Bopomofo
Georgian Supplement	Medefaidrin	Kannada	Bopomofo Extended
Glagolitic	Mende Kikakui	Kharoshthi	CJK Unified Ideographs (Han) (35MB)
Glagolitic Supplement	Meroitic	Khojki	CJK Extension A (6MB)
Gothic	Meroitic Cursive	Khudawadi	CJK Extension B (40MB)
Greek	Meroitic Hieroglyphs	Lepcha	CJK Extension C (3MB)
Greek Extended	N'Ko	Limbu	CJK Extension D
Ancient Greek Numbers		Mahajani	

Unicode Textual Data

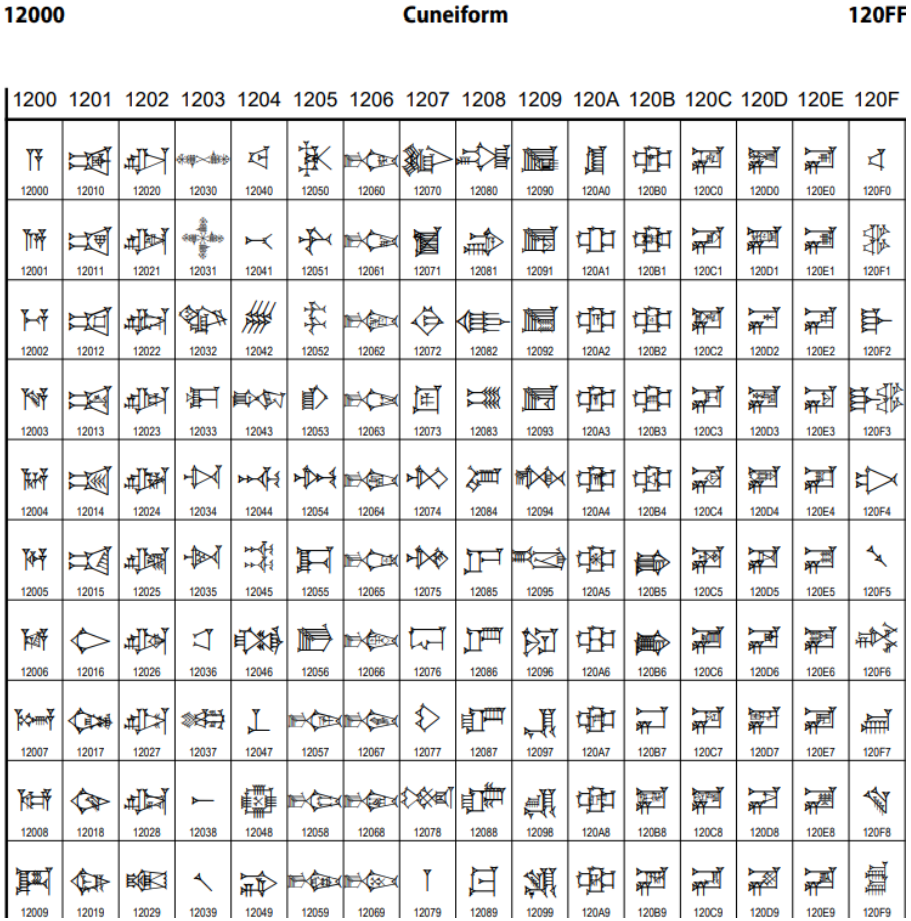

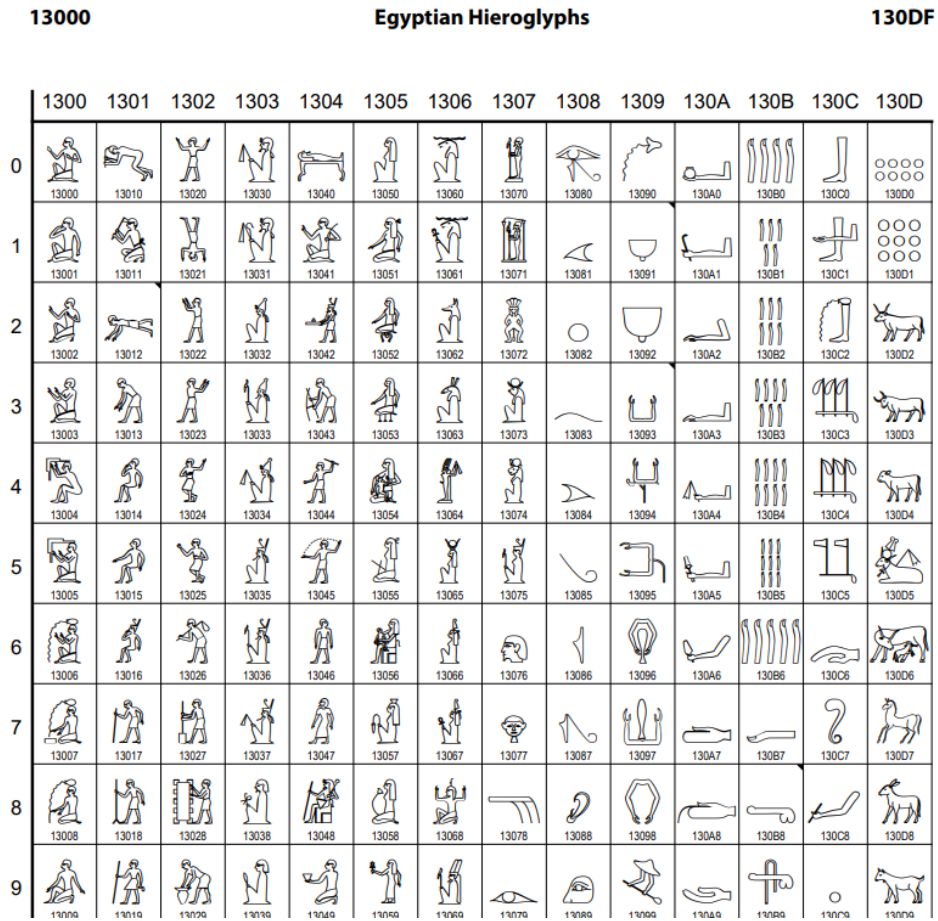

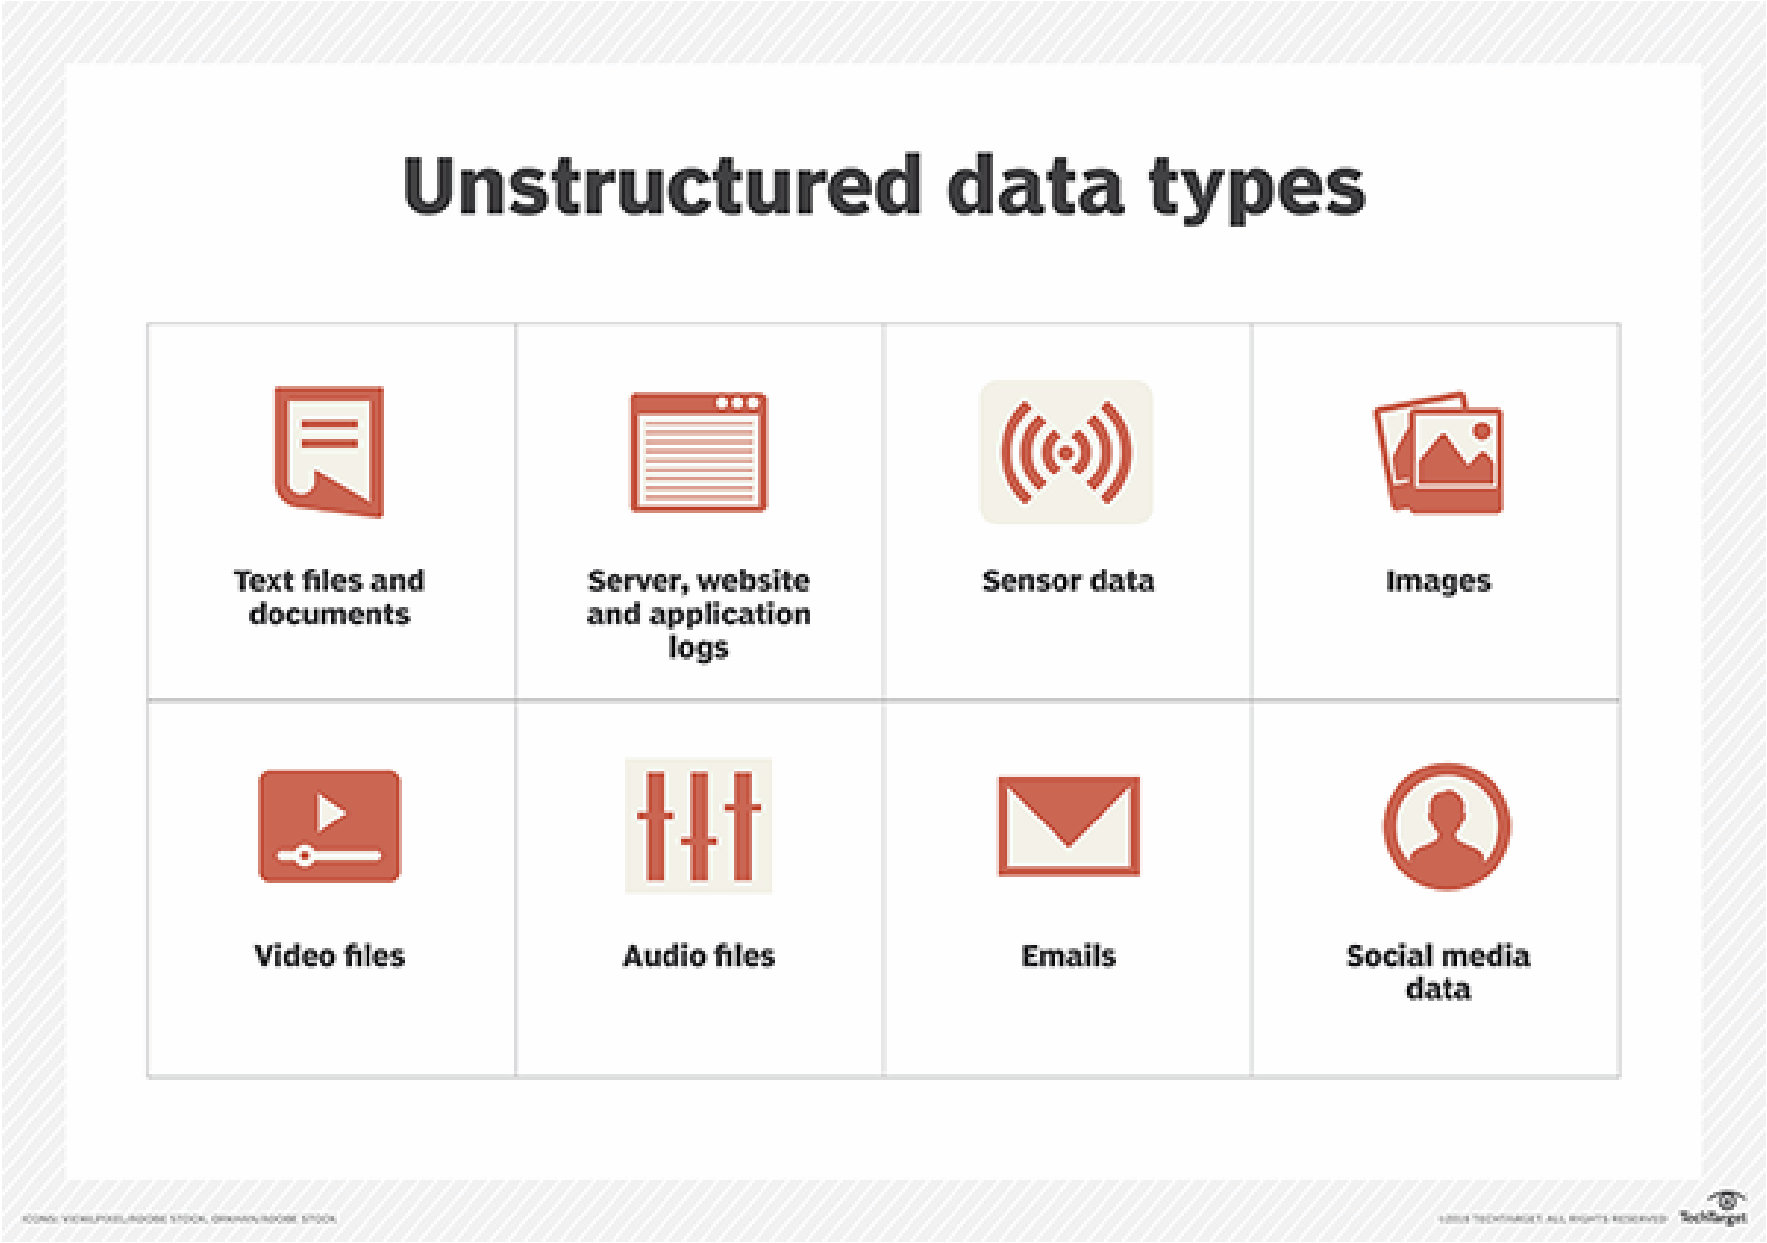
Unstructured data types
Text files and documents
Server, website and application logs
Sensor data
Images
Video files
Audio files
Emails
Social media data

text
as
data
textual
methods
research
software
advanced
exist
Finally
book-length
social
models
sciences
scaling
approach
develop
applications
users
training
QUANTESS
texts
new
techniques
researchers
analyzing
quantitative
analysis
statistical

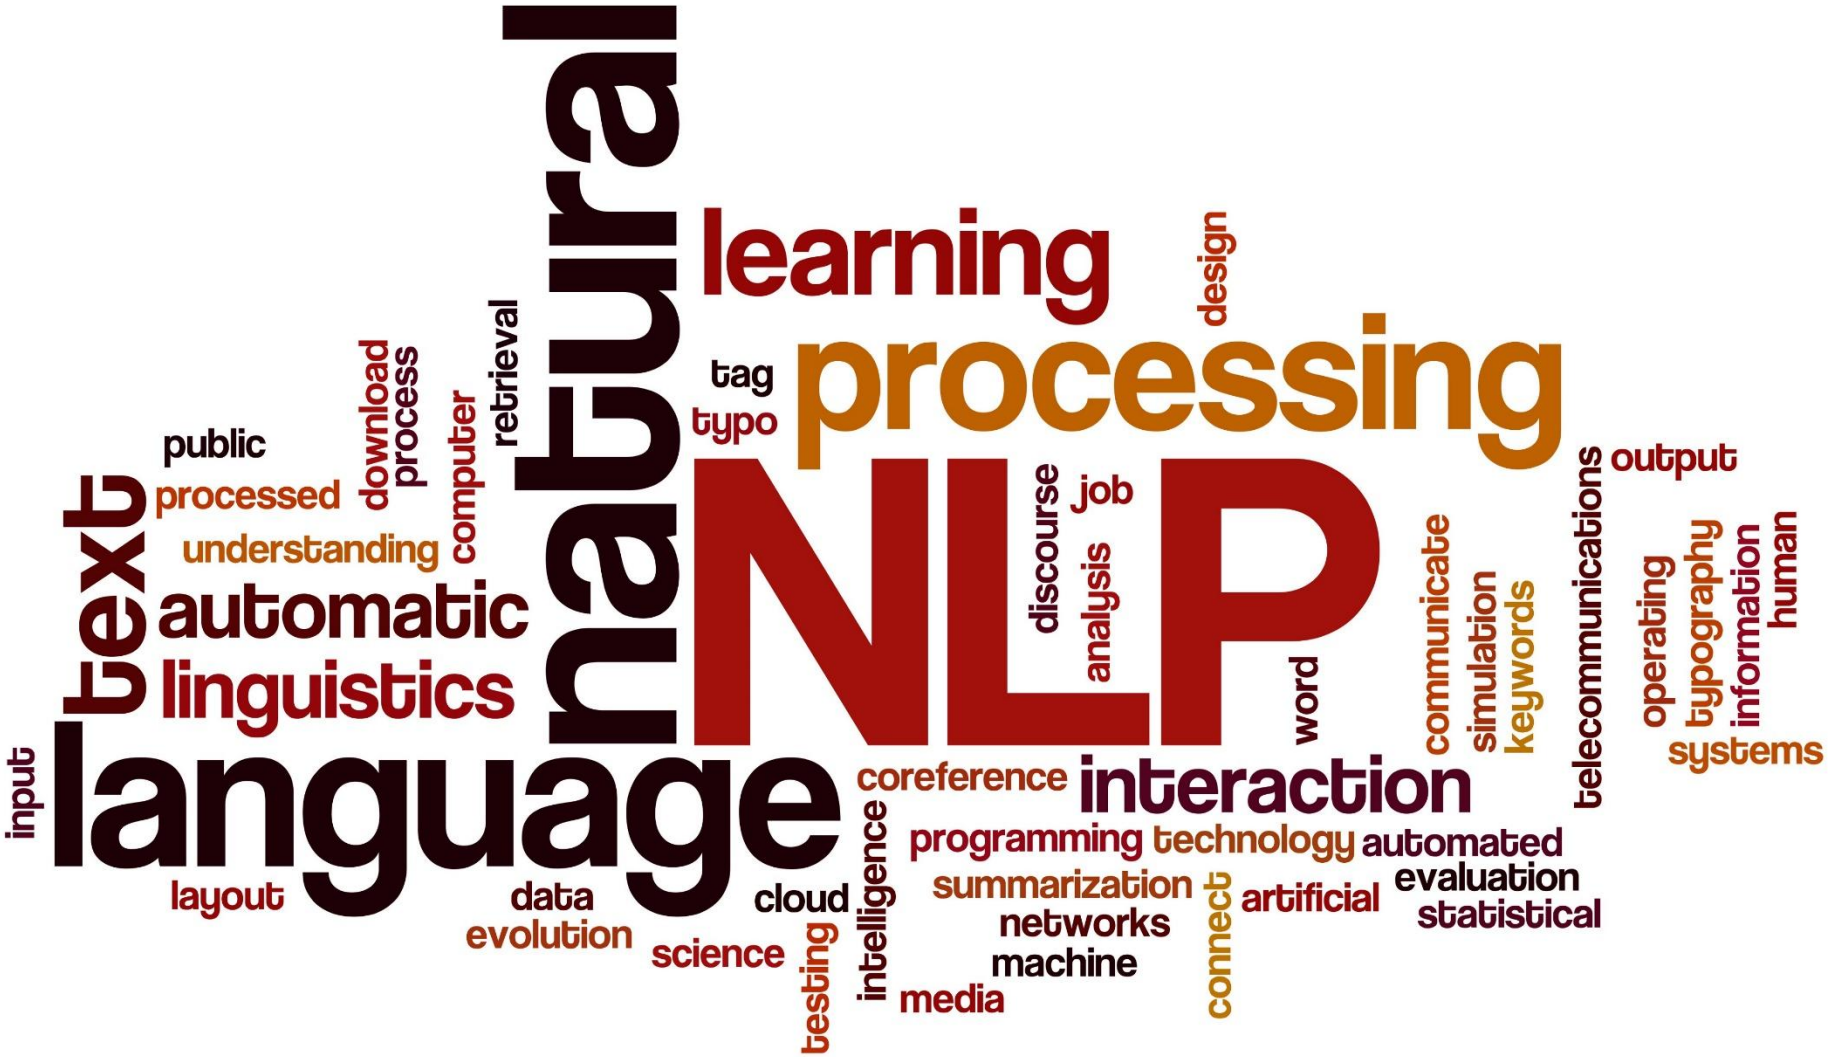
natural
learning
processing
NLP
language
text
automatic
linguistics
interaction
design
tag
typo
retrieval
download
process
computer
public
processed
understanding
input
layout
data
evolution
science
testing
cloud
intelligence
coreference
programming
technology
automated
summarization
evaluation
artificial
statistical
networks
machine
media
connect
discourse
analysis
job
word
communicate
simulation
keywords
telecommunications
output
operating
typography
information
human
systems

Natural Language Processing

- **Natural Language Processing (NLP)** is a subfield of
  - Linguistics
  - computer science
  - artificial intelligence

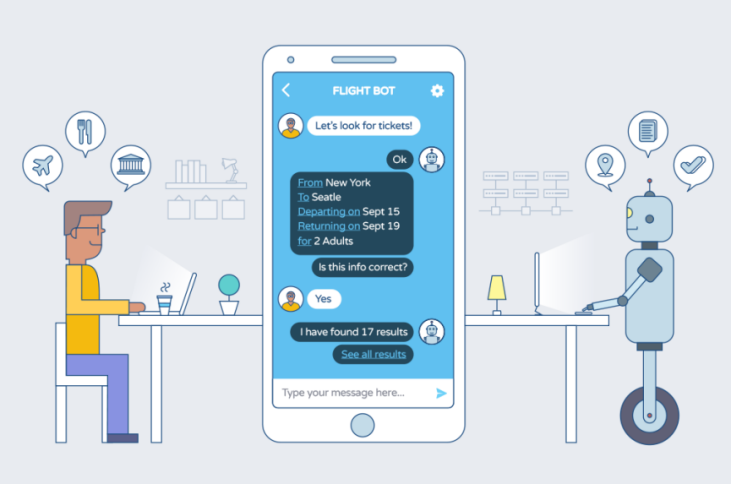

- concerned with the interactions between **computers** and **human language** in particular **how to** program computers to **process and analyze large amounts of natural language data**.

Natural Language Processing

- The **goal** is a computer capable of **"understanding"** the contents of documents, including the contextual nuances of the language within them.
  - The technology can then accurately **extract information** and **insights contained in the documents** as well as categorize and organize the documents themselves.
  - Challenges in NLP frequently involve **speech recognition, natural language understanding, and natural language generation**.

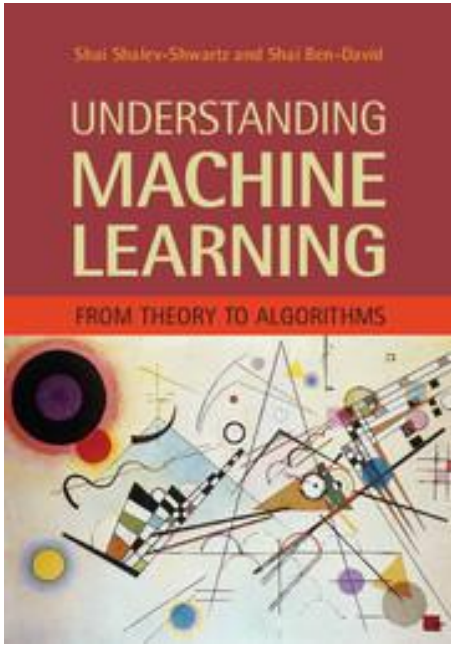

Natural Language Processing

- **NLP** is **word processing** in **Natural Language** or Human Language Domain.
- **NLP** is **String Processing**.
- **Application Examples**
  - Word Segmentation. “ตากลม” “หลวงตามหาบัว”
  - Machine Understanding.
  - Automatic FAQ / Chatbot.
  - Visual Teacher.
  - Machine Translation.
  - Search Engine.Text Mining

Word Segmentation

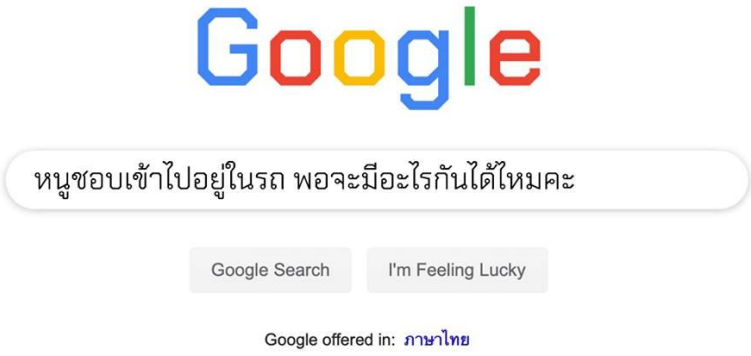


```
from pythainlp.tokenize import word_tokenize
st1 = word_tokenize('ขอให้หายนะค่ะ',engine='longes
st2 = word_tokenize('ขอให้หายนะคะ',engine='longes
st3 = word_tokenize('เศยอมแล้ว',engine='longest')
st4 = word_tokenize('หลวงตามหาบัว',engine='longes
st5 = word_tokenize('หมอยโส่ธร',engine='longest')
st6 = word_tokenize('หาทีมอาตมายกย้ายของ 4-5 คน',engine='longest')
```

```
print(st1)
print(st2)
print(st3)
print(st4)
print(st5)
print(st6)
```

IDLE Shell 3.10.2

File Edit Shell Debug Options Window Help

```
Python 3.10.2 (tags/v3.10.2:a58ebcc, Jan 17 2022, 14:12:15) [MSC v.19
(AMD64)] on win32
Type "help", "copyright", "credits" or "license()" for more informati
>>>
= RESTART: C:\Users\Acer\AppData\Local\Programs\Python\Python310\Word
on.py
['ขอให้', 'หายนะ', 'ค่ะ']
['ขอให้', 'หายนะ', 'คะ']
['เศย', 'อม', 'แล้ว']
['หลวงตา', 'มหา', 'บัว']
['หมอย', 'โส่', 'ธร']
['หา', 'ทีม', 'อาตมา', 'ยก', 'ย้าย', 'ของ', ' ', '4', '-', '5', ' ', 'คน'
```

Word Preprocessing

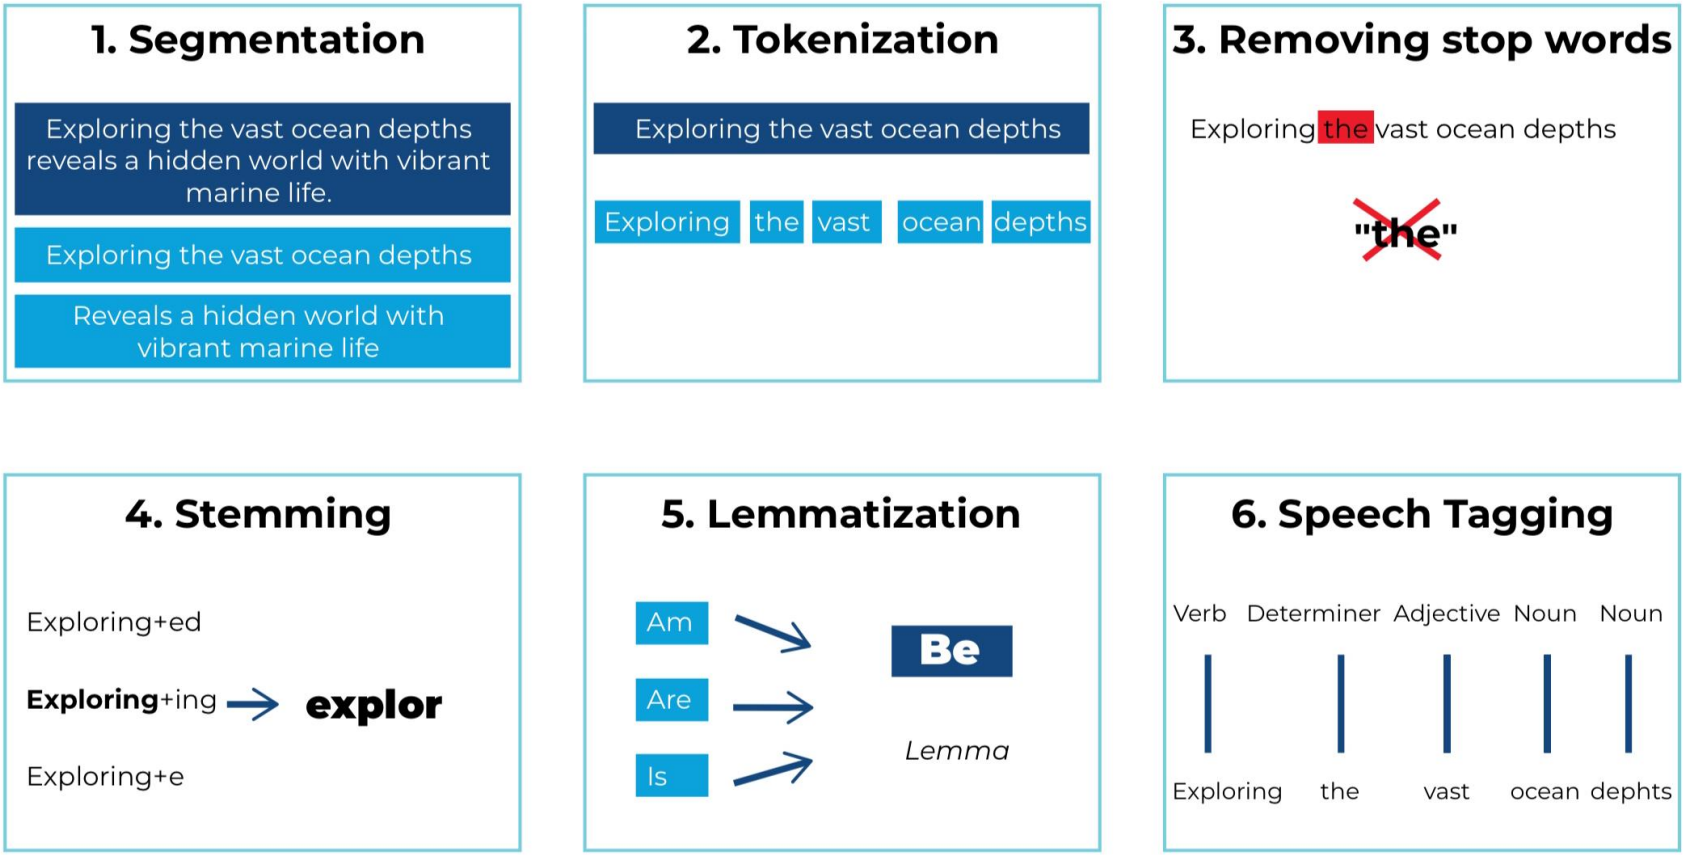

Understanding Language

Automatic FAQ / Chatbot

mastercard

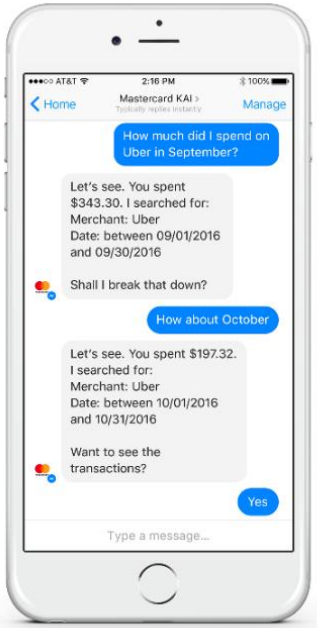

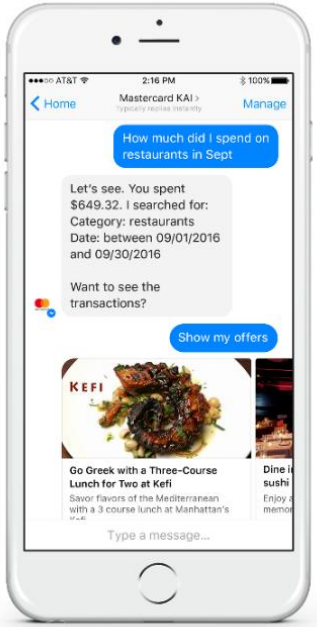

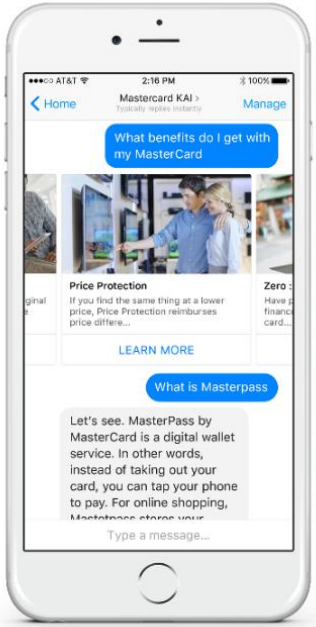

POWERED BY
Kasisto

Application Examples

- **SPEECH SYNTHESIS (Text to Speech)**

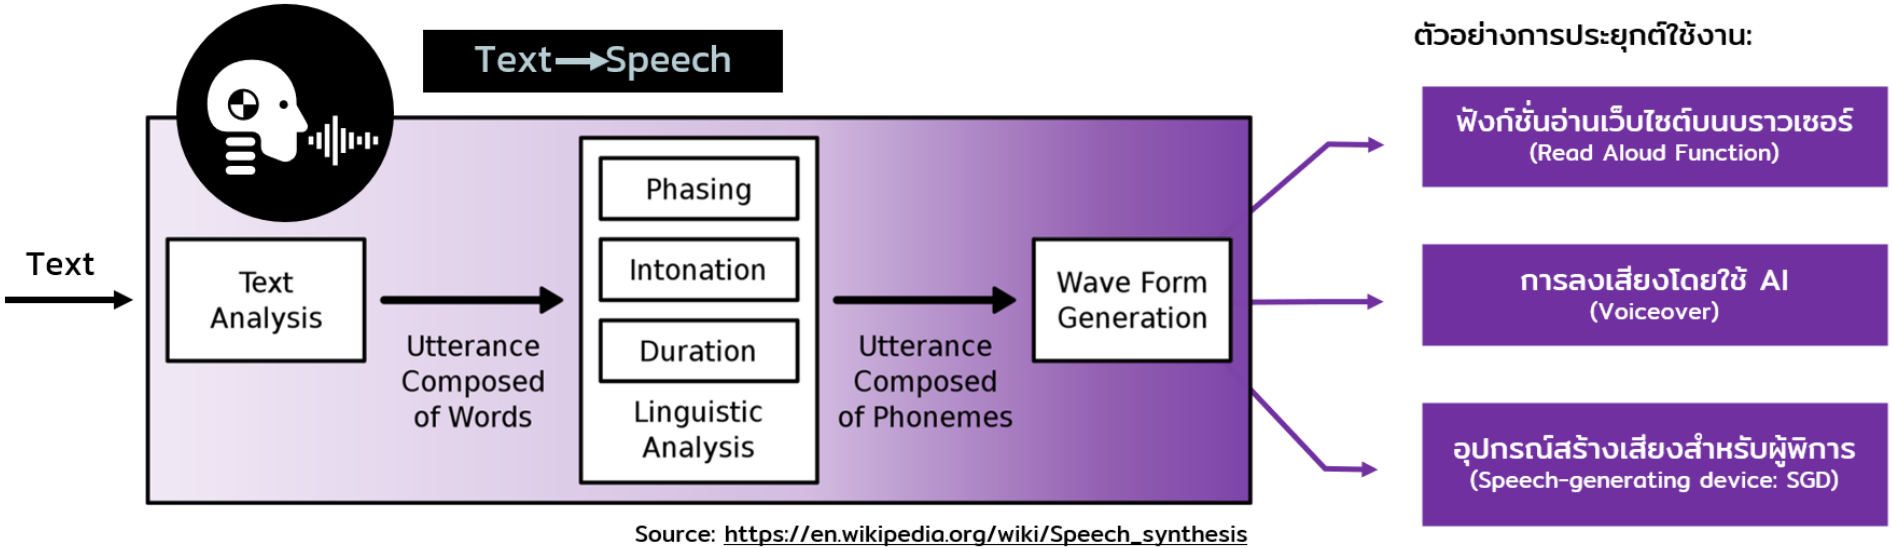

Source: https://en.wikipedia.org/wiki/Speech_synthesis

Application Examples

Google Translate

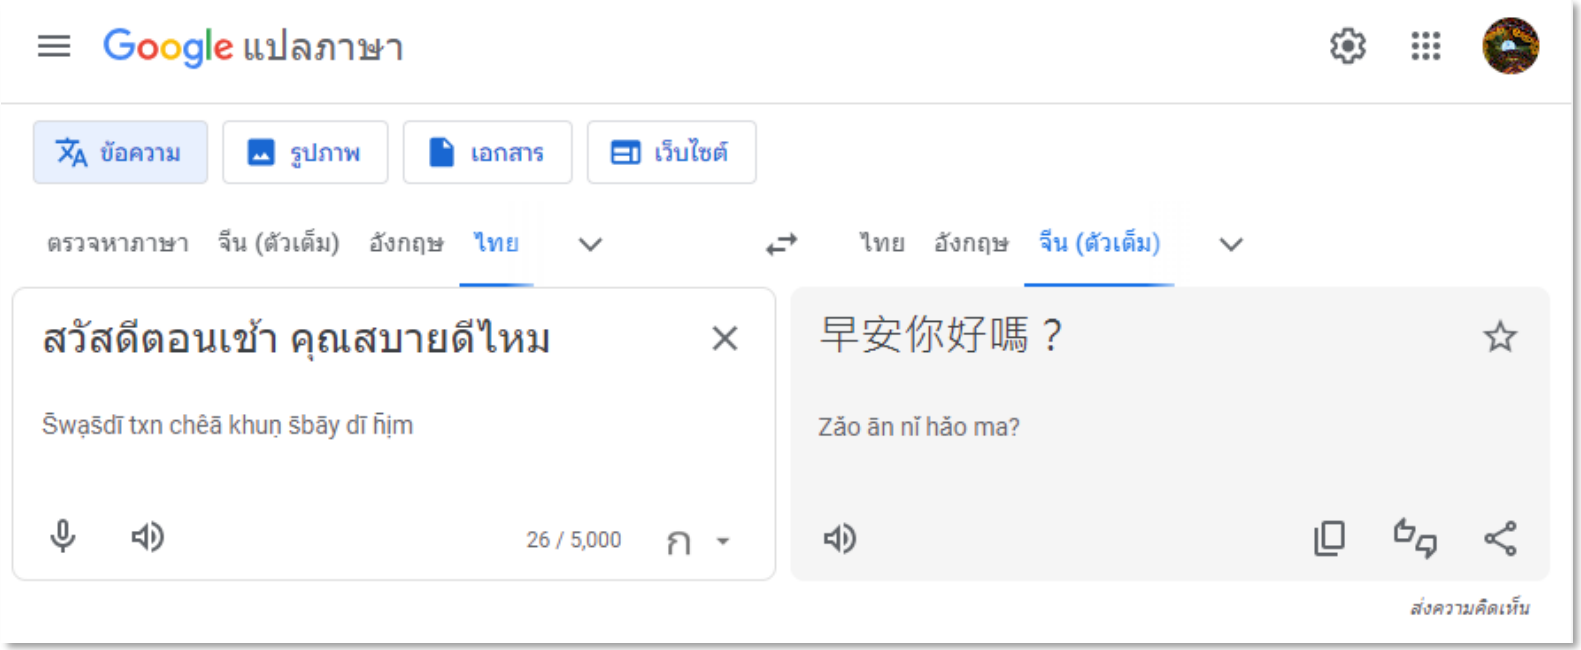

Application Examples

- **Machine Translation** --> Thai Language – English Language.
- **“เขา”** จะถูกแปลไปเป็นอะไร???
- **“Horn” or “He” or “She” or “Hill”**
- Machine Translator???

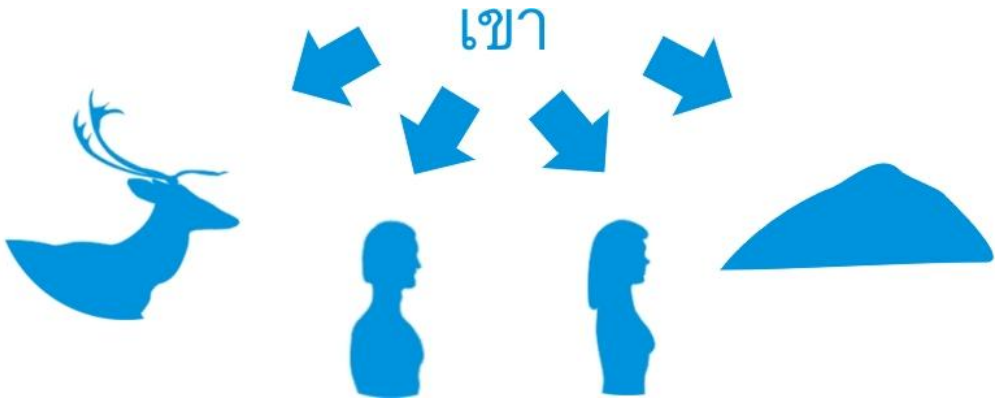

Application Examples

- Text **Summarization**, Paragraph Extraction
- **Word Ambiguous** Problem for Search Engine.
- **Application Examples**
  - น้ำฝน (Human Name or Rain).
  - ขอให้หายนะค่ะ, ขอให้หายนะคะ (การใส่หมายเอกหรือไม่ใส่ความหมายตรงกันข้าม)
  - เคยอมแล้ว (เกิดความกำกวมเชิงความหมายหากอ่านผิด)
  - แซบ vs. แซ่บ (เกิดความกำกวมในการใช้งาน)

Application Examples

- **พจนานุกรม** ฉบับราชบัณฑิตยสถาน มีทั้งสิ้น ๔ ฉบับ
  - ปี ๒๔๙๓ สะกดว่า “แซบ” (ไม่มีไม้เอก)
  - ปี ๒๕๒๕ สะกดว่า “แซบ” (ไม่มีไม้เอก)
  - ปี ๒๕๔๒ สะกดว่า “แซบ” (ไม่มีไม้เอก)
  - **ปี ๒๕๕๔ สะกดว่า “แซ่บ” (มีไม้เอก)**
- คำเริ่มเปลี่ยนใหม่มาเป็น “แซ่บ” (แบบมีไม้เอก) ในฉบับพุทธศักราช ๒๕๕๔ ซึ่งเป็นฉบับล่าสุด ที่เหลือ ๓ ฉบับในอดีตสะกดว่า “แซบ” (แบบไม่มีไม้เอก)

Application Examples

- การค้นพบ**ความชาญฉลาด**จาก**ฐานข้อมูล** (Intelligent Retrieval from Database)

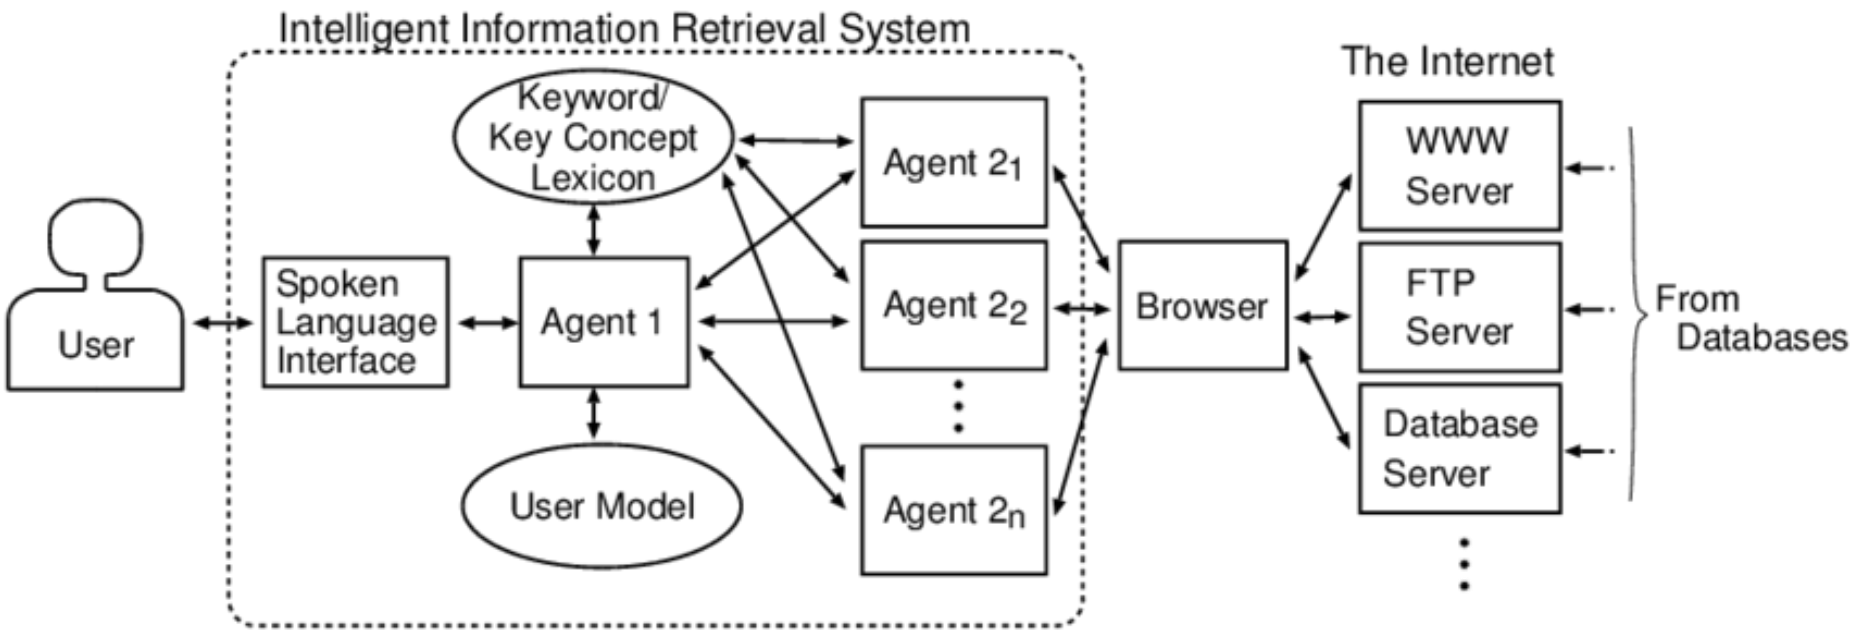

Application Examples

- **Intelligent Retrieval (IR)** from **Database**
  - **Information** :: Web Page, Document, Book, NEWS, Image, Other Multimedia.

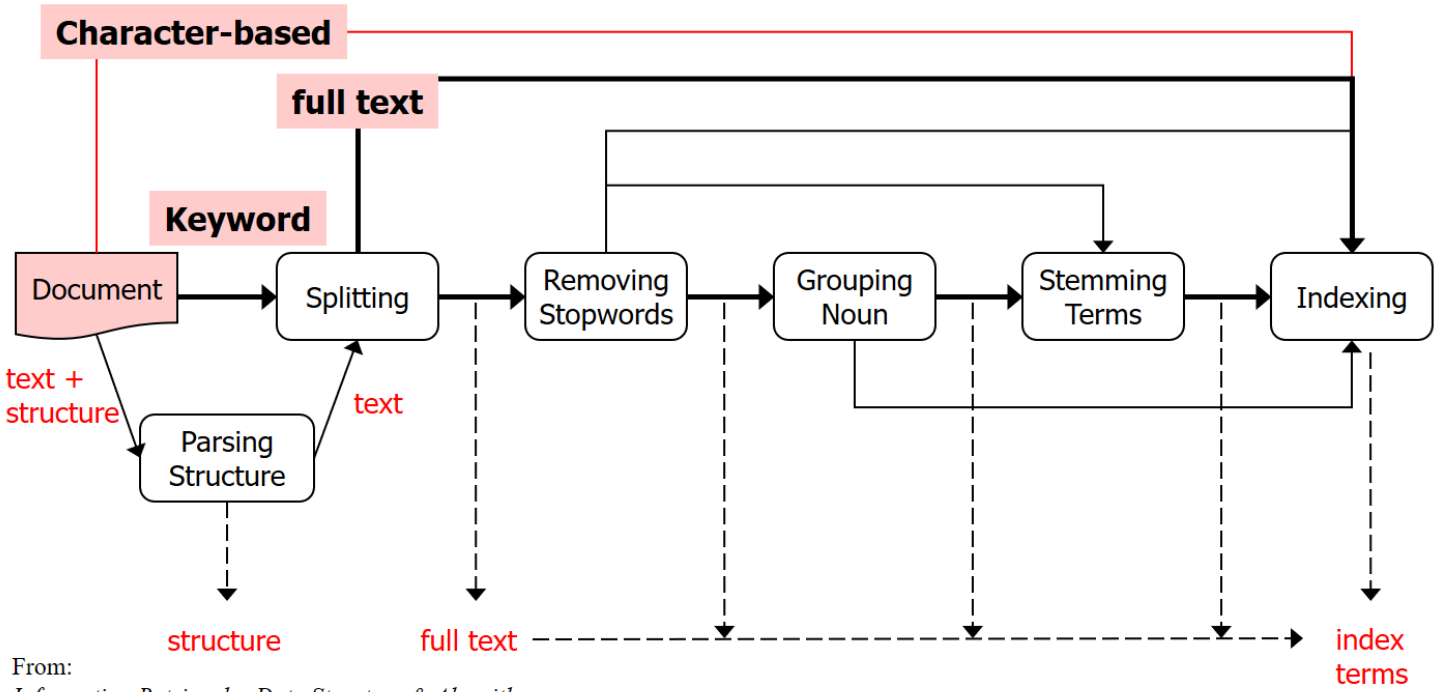

From:
Information Retrieval – Data Structure & Algorithms,
Edited by William B. Frakes and Ricardo Baeza-Yates,
Prentice Hall, 1992

Application Examples

Raw Data

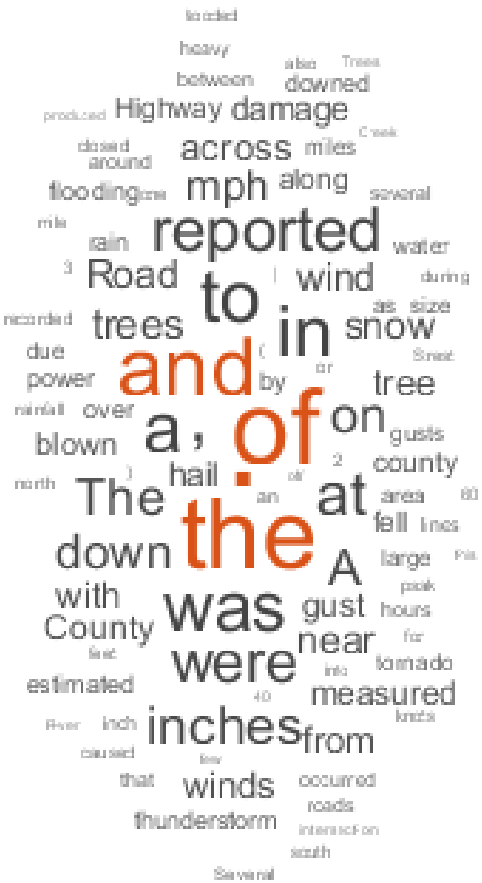

Cleaned Data

Application Examples

- **Social Listening** - การรวบรวมข้อมูลความเห็นของประชาชนทั่วไป (Crawling) จากเว็บไซต์ หรือ Social Media ยอดนิยมต่างๆ เช่น Facebook, Instagram, Twitter เป็นต้น เพื่อทราบว่าประชาชนทั่วไปสนใจหรือมีการพูดถึงอย่างไรบ้าง

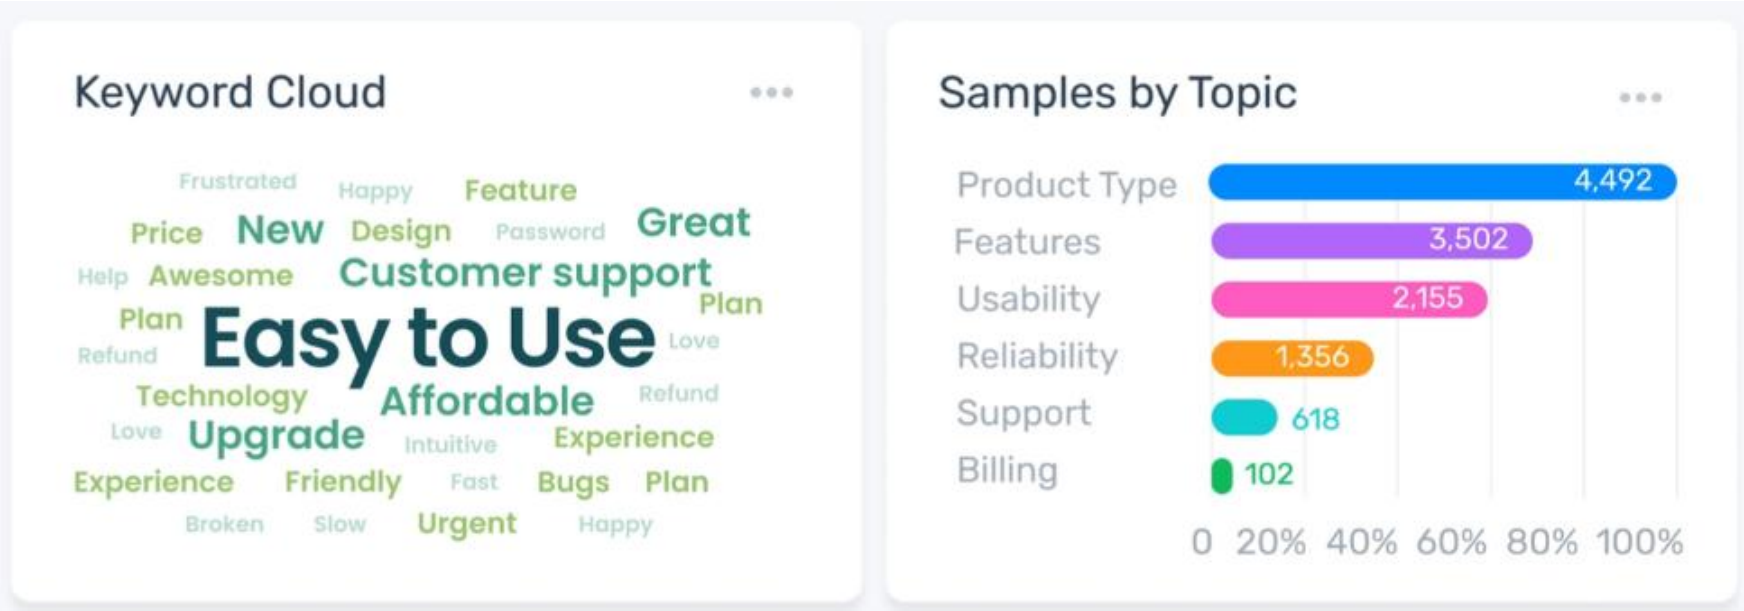

Text Genaration

- **ตัวอย่างการประยุกต์ใช้ Text Generation:**
- แปลภาษา
- สร้างสรรค์เนื้อหา (Content Creation) เช่น ตอบอีเมล เขียนบล็อก เขียนคำอธิบายเกี่ยวกับผลิตภัณฑ์หรือโฆษณา
- สรุปเนื้อหา/บทความ
- Chatbot หรือ Virtual Assistant
- คิดเนื้อหา/คำอธิบาย (เช่น Title, Metadata, Keyword) เพื่อให้ Search Engine แสดงผลการค้นหาได้ดีขึ้น (SEO-Optimized content)
- เขียนโปรแกรม

ChatGPT
Copilot
Gemini
OpenThaiGPT
Claude
perplexity
Pathumma LLM

Application Examples

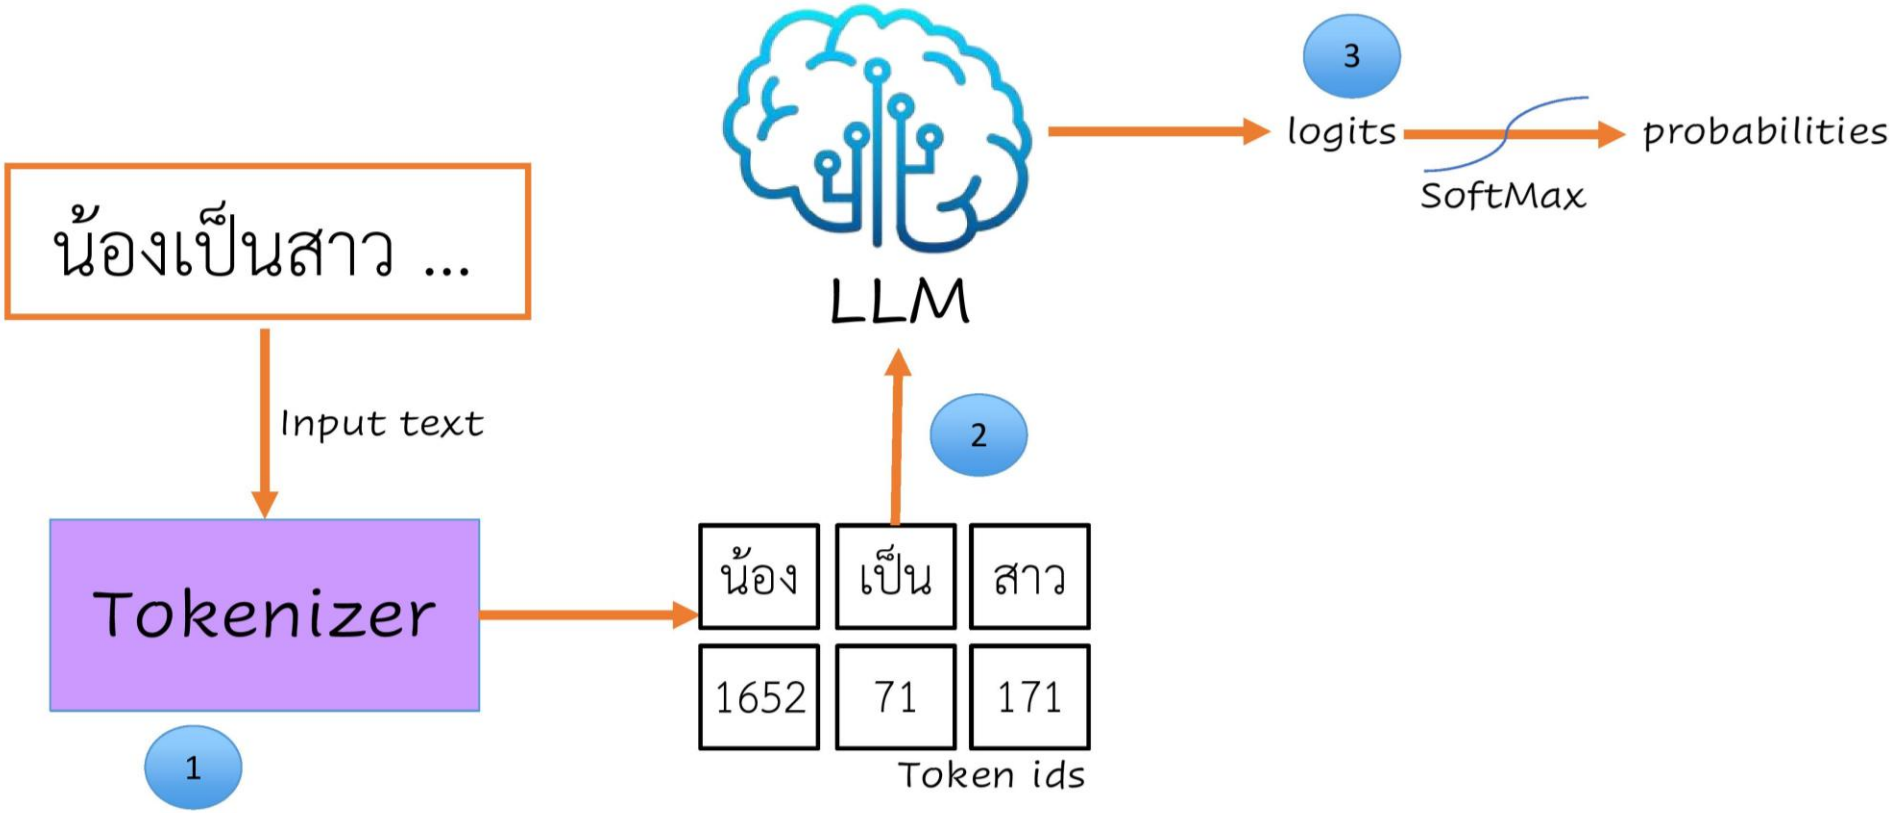

Source: การบรรยายพิเศษเรื่อง LLM โดย ดร.ศราวุธ คงยัง (NECTEC)

Application Examples

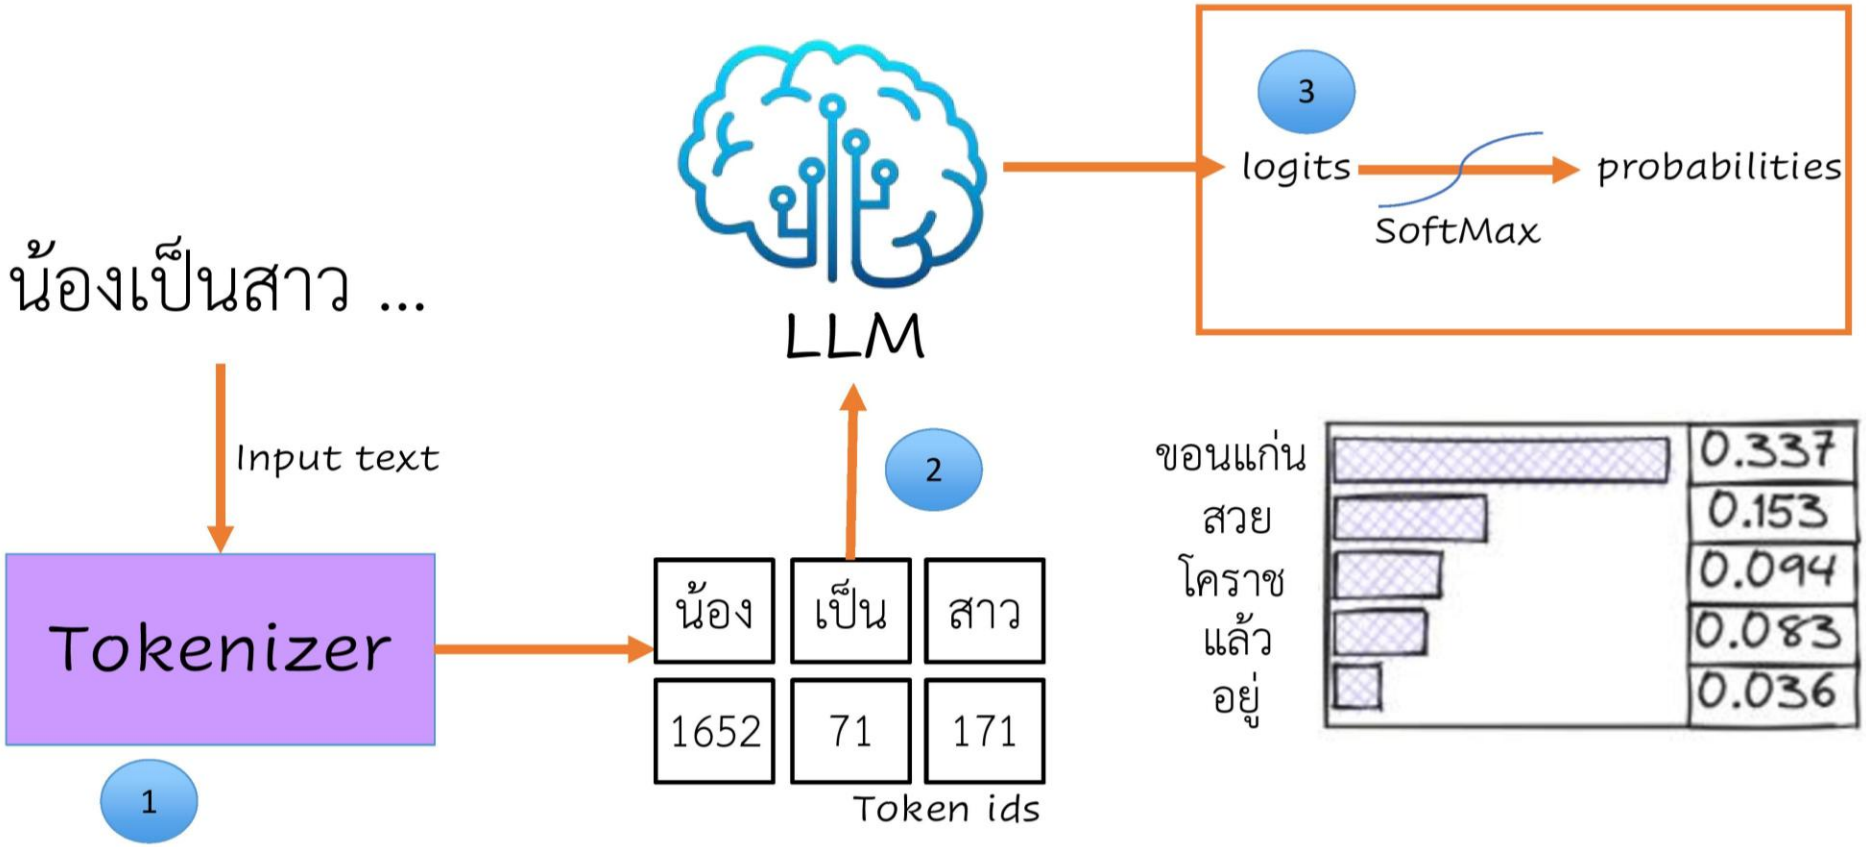

Source: การบรรยายพิเศษเรื่อง LLM โดย ดร.ศราวุธ คงยัง (NECTEC)

Application Examples

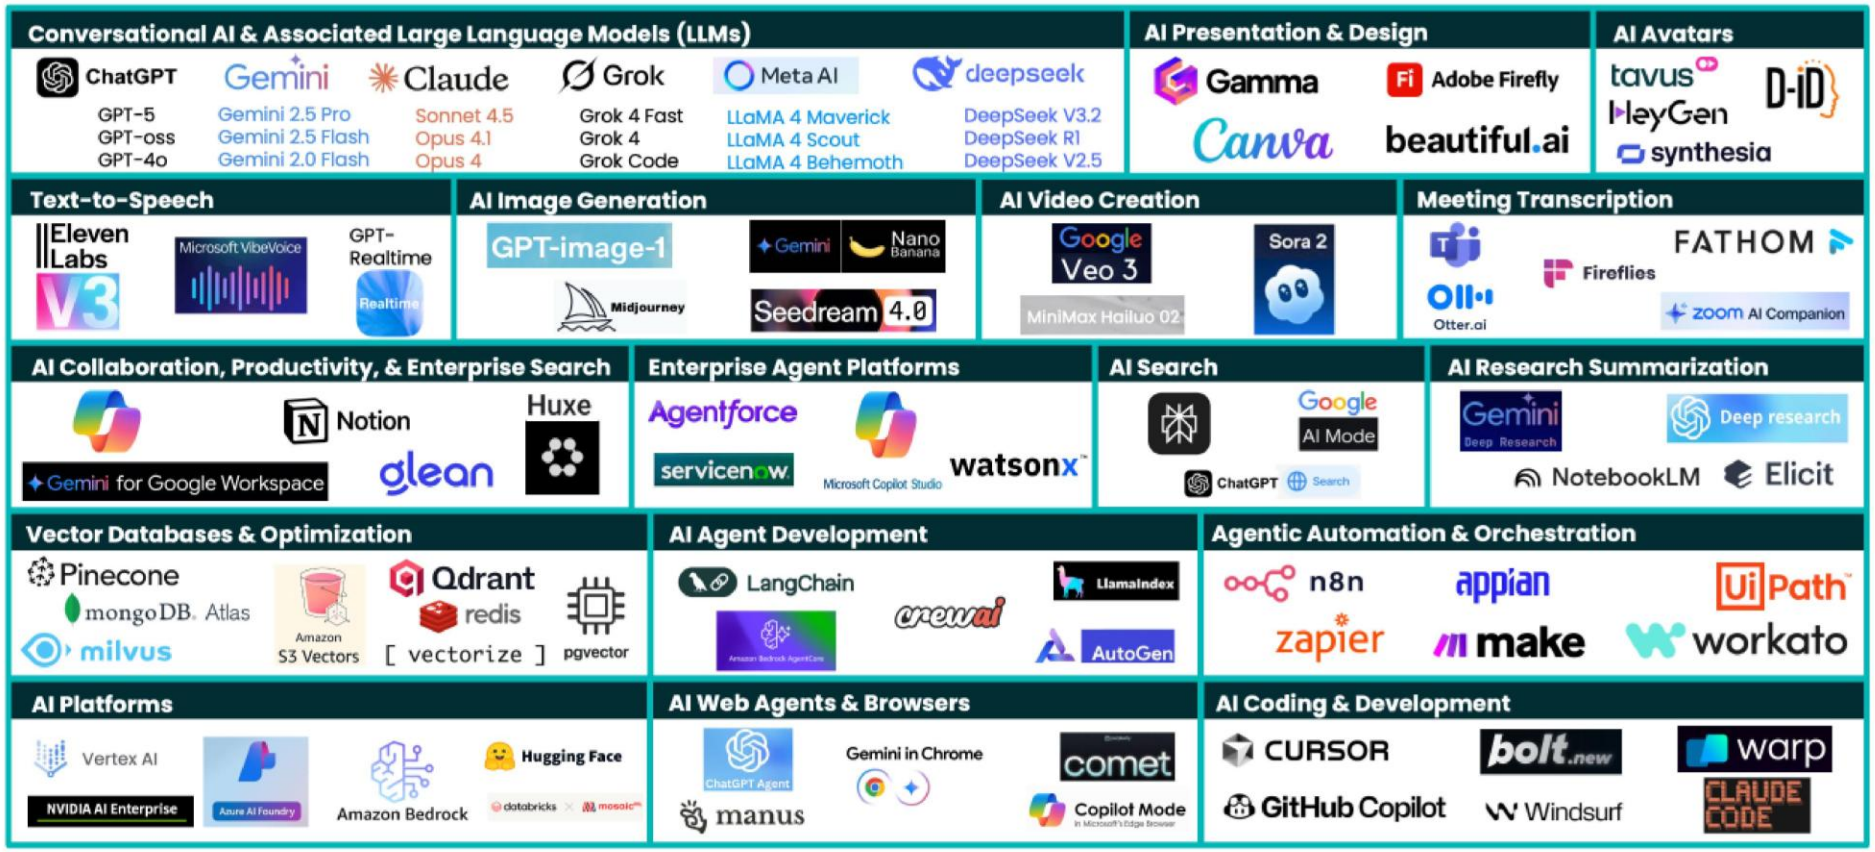

Application Examples

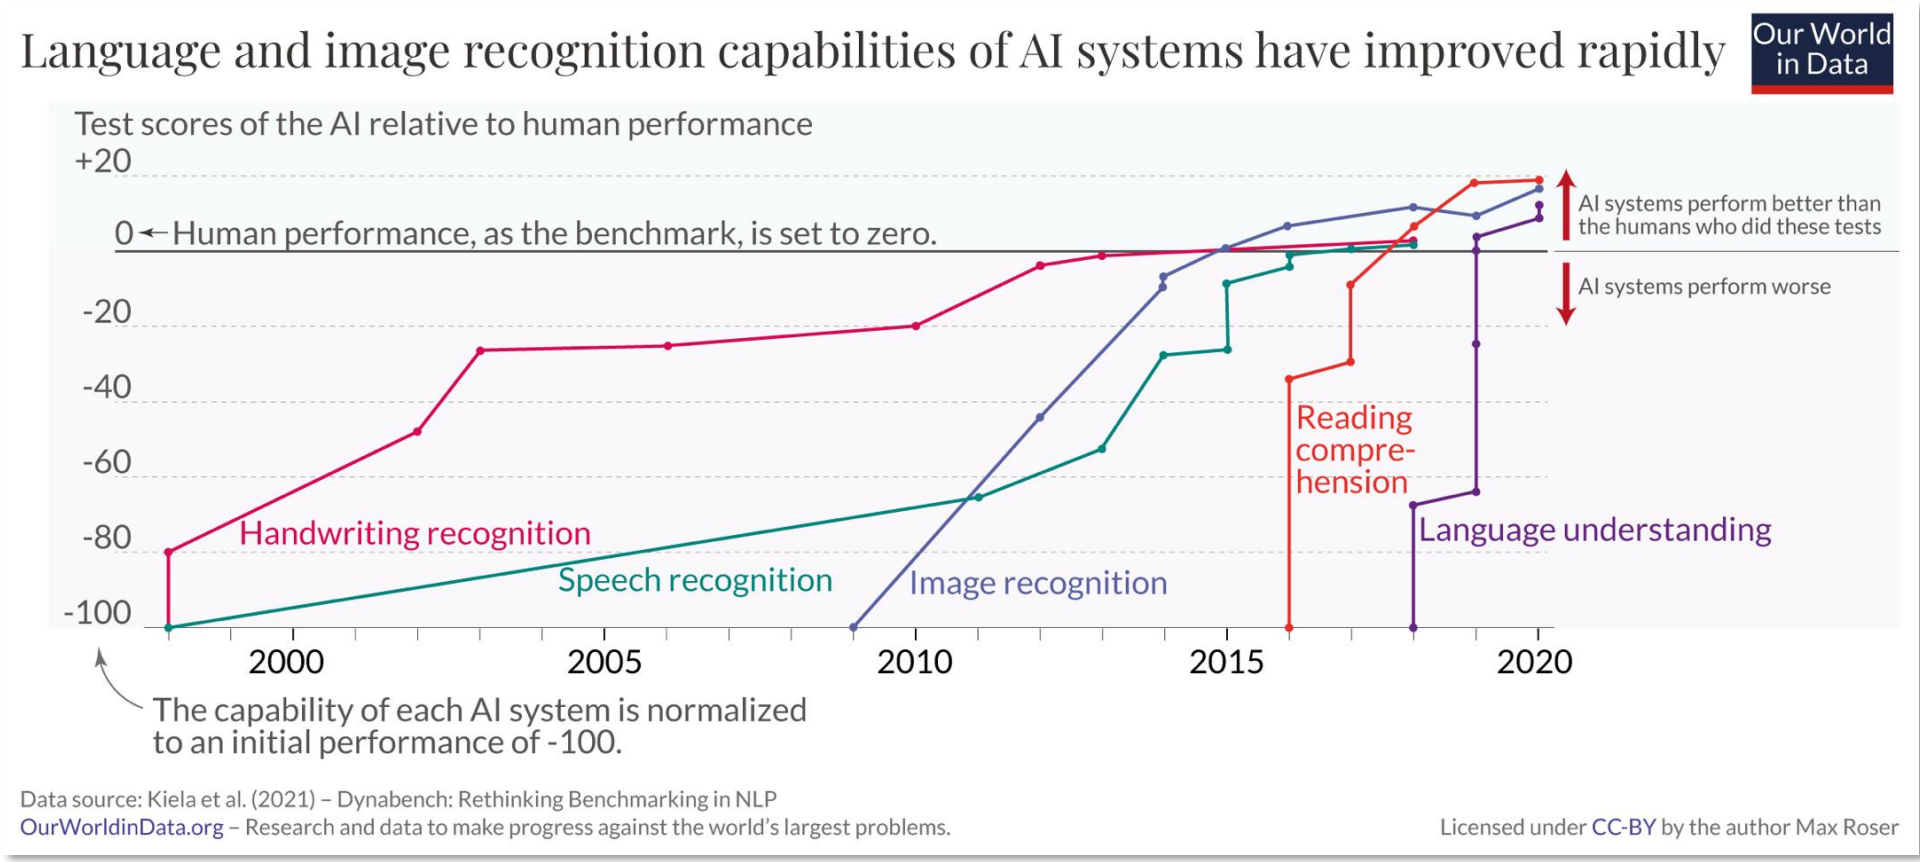

PyThaiNLP

- The **PyThaiNLP** Project
  - is a **Thai Natural Language Processing** project. We build softwares and datasets for Thai language. Our Main Project is PyThaiNLP.

PyThaiNLP

- PyThaiNLP is a **Python package**
  - for **text processing and linguistic analysis, similar to nltk, with focus on Thai language.**

A

B

Word	Frequency
Confront	4
Region	4
Sincere	4
Connection	3
Science	3
Clinical practice	3
Self-esteem	2
Ethics	2
Community	2
Trust	2
Achievement	2

PyThaiNLP

- **ขั้นตอนการติดตั้งใช้งานผ่าน Dos Mode (cmd)**
- ทำการตรวจสอบ **Version** ของ **PIP** ตัวช่วยติดตั้งของภาษาไพธรอนว่าเป็นเวอร์ชั่นล่าสุดหรือยัง รวมทั้งตรวจสอบเวอร์ชั่นล่าสุดของแพกเกตอื่น ถ้า pip เป็น version เก่าให้ทำการอัพเดทก่อน

  python -m pip install --upgrade pip
- การใช้คำสั่ง **pip list** สำหรับตรวจสอบเวอร์ชั่นล่าสุดและตรวจสอบว่าเครื่องของเรามี Lib หรือ Package ใดติดตั้งไว้บ้าง
- การติดตั้ง **PyThaiNLP version 5.2.0 (Dec 20,2025)**
- ติดตั้งด้วยคำสั่ง **pip install pythainlp**

  pip install -U pythainlp (กรณีมีเวอร์ชั่นก่อนลง)

PyThaiNLP

- **ขั้นตอนที่ 1 ติดตั้ง Python และใช้คำสั่ง pip list**

```
Select Command Prompt
Microsoft Windows [Version 10.0.22000.1455]
(c) Microsoft Corporation. All rights reserved.

C:\Users\Acer>pip list
Package    Version
---------- -------
pip        22.3.1
setuptools 65.5.0

[notice] A new release of pip available: 22.3.1 -> 23.0
[notice] To update, run: python.exe -m pip install --upgrade pip

C:\Users\Acer>
```

(1) ออกไปที่ Dos Command Prompt ด้วยคำสั่ง cmd
(2) พิมพ์คำสั่ง pip list หาก pip เป็นตัวเก่าจะมีข้อความแจ้งให้ติดตั้งตัวใหม่

PyThaiNLP

- **ขั้นตอนที่ 2 ติดตั้ง pip ใหม่ แล้วลอง pip list อีกครั้ง**

Command Prompt

```
[notice] A new release of pip available: 22.3.1 -> 23.0
[notice] To update, run: python.exe -m pip install --upgrade pip

C:\Users\Acer>python.exe -m pip install --upgrade pip
Requirement already satisfied: pip in c:\users\acer\appdata\local\programs\python\python311\lib\site-packages (22.3.1)
Collecting pip
  Using cached pip-23.0-py3-none-any.whl (2.1 MB)
Installing collected packages: pip
  Attempting uninstall: pip
    Found existing installation: pip 22.3.1
    Uninstalling pip-22.3.1:
      Successfully uninstalled pip-22.3.1
Successfully installed pip-23.0

C:\Users\Acer>pip list
Package    Version
---------- -------
pip        23.0
setuptools 65.5.0

C:\Users\Acer>
```

(1) พิมพ์คำสั่ง python.exe -m pip install -update pip

(2) ทดลองพิมพ์คำสั่ง pip list อีกครั้ง เพื่อดู Version ของ pip ล่าสุดยังต้องเป็นเวอร์ชั่นล่าสุด คือ เวอร์ชั่น 25.3 (ณ วันที่ 25 ธันวาคม 2568)

PyThaiNLP

- **ขั้นตอนที่ 3 ติดตั้งไลบรารี่ PythaiNLP**

Command Prompt

```
C:\Users\Acer>pip install pythainlp
Collecting pythainlp
  Downloading pythainlp-3.1.1-py3-none-any.whl (9.6 MB)
     ---------------------------------------- 9.6/9.6 MB 3.0 MB/s eta 0:00:00
Collecting requests>=2.22.0
  Downloading requests-2.28.2-py3-none-any.whl (62 kB)
     ---------------------------------------- 62.8/62.8 kB 3.5 MB/s eta 0:00:00
Collecting charset-normalizer<4,>=2
  Downloading charset_normalizer-3.0.1-cp311-cp311-win_amd64.whl (96 kB)
     ---------------------------------------- 96.0/96.0 kB 2.7 MB/s eta 0:00:00
Collecting idna<4,>=2.5
  Downloading idna-3.4-py3-none-any.whl (61 kB)
     ---------------------------------------- 61.5/61.5 kB 1.1 MB/s eta 0:00:00
Collecting urllib3<1.27,>=1.21.1
  Downloading urllib3-1.26.14-py2.py3-none-any.whl (140 kB)
     ---------------------------------------- 140.6/140.6 kB 4.2 MB/s eta 0:00:00
Collecting certifi>=2017.4.17
  Downloading certifi-2022.12.7-py3-none-any.whl (155 kB)
     ---------------------------------------- 155.3/155.3 kB 3.1 MB/s eta 0:00:00
Installing collected packages: charset-normalizer, urllib3, idna, certifi, requests, pythainlp
Successfully installed certifi-2022.12.7 charset-normalizer-3.0.1 idna-3.4 pythainlp-3.1.1 requests-2.28.2 urllib3-1.26.14

C:\Users\Acer>pip list
Package            Version
------------------ ---------
certifi            2022.12.7
charset-normalizer 3.0.1
idna               3.4
pip                23.0
pythainlp          3.1.1
requests           2.28.2
setuptools         65.5.0
urllib3            1.26.14
```

(1) พิมพ์คำสั่ง pip install pythainlp (ต้องต่ออินเตอร์เน็ต)

(2) ทดลองคำสั่ง pip list อีกครั้ง เพื่อดูว่ามีรายการ pythainlp หรือยัง

PyThaiNLP

- **ขั้นตอนที่ 4 ทดลองเรียกใช้งาน PythaiNLP**

```
Command Prompt
Microsoft Windows [Version 10.0.22000.1455]
(c) Microsoft Corporation. All rights reserved.

C:\Users\Acer>python
Python 3.11.2 (tags/v3.11.2:878ead1, Feb  7 2023, 16:38:35) [MSC v.1934 64 bit (AMD64)] on win32
Type "help", "copyright", "credits" or "license" for more information.
>>> import pythainlp
>>> ^Z

C:\Users\Acer>_
```

(1) พิมพ์คำสั่ง python จาก Dos Mode จะเข้าสู่ editer
(2) ลองตรวจสอบ Python Version ได้ในภาพเป็น Python 3.11.2
(3) ทดลองพิมพ์คำสั่งในภาษาไพธรอน import pythainlp
(4) หากไม่มีการฟ้องข้อผิดพลาด แสดงว่าติดตั้งครบถ้วน สมบูรณ์

PyThaiNLP version 5.2.0

- รายละเอียดใช้งาน และคู่มือการใช้งาน **https://pypi.org/project/pythainlp/**
- **https://pythainlp.github.io**

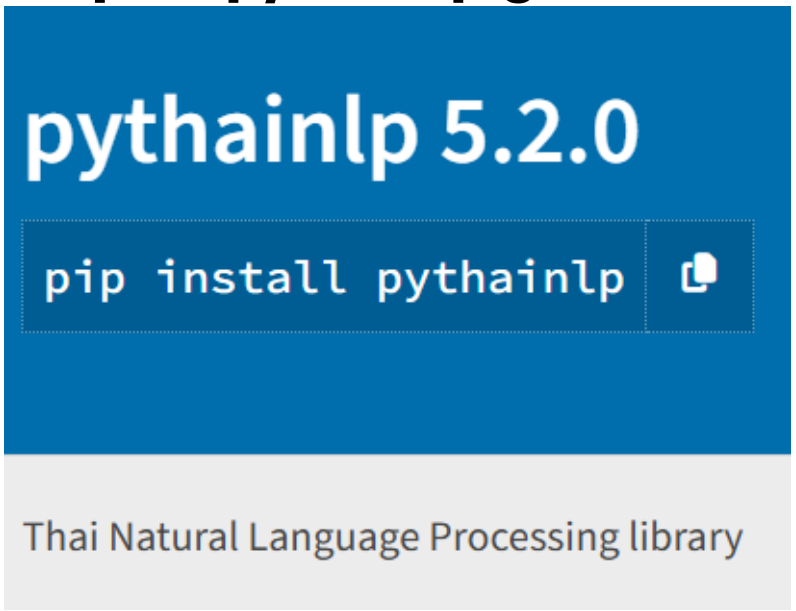

การติดตั้ง PyThaiNLP และการใช้งาน

- **WorkShop IV** :: ให้นักศึกษาทำการติดตั้ง **PyThaiNLP ver 5.2.0**
- ทดลองใช้งานตามที่แนะนำ จากนั้นทำโจทย์ประยุกต์ตามเอกสารแนบ