ไลบรารี่สำหรับข้อมูลเชิงดิจิทัล
Library for Digital Data

ผู้ช่วยศาสตราจารย์โอภาส วงษ์ทวีทรัพย์
Asst.Prof.Opas Wongtaweesap (Aj'OaT)
ภาควิชาคอมพิวเตอร์
คณะวิทยาศาสตร์ มหาวิทยาลัยศิลปากร
URL:: http://www.facebook.com/OaTCoM **E-mail::** oatcomster@gmail.com

unstructured
information
data
structure
tagged
structured
may
still
ambiguities
typically
form
html
files
estimates
processing
content
documents
text
web
page
capture
ways
meaning
word
well
inherent
elements
defined
implied
techniques
relevancy-based
difficult
example
software
widely
conceptual
semi-structured
syntax
research
facts
video
examples
other
text-heavy
highly
data
instance
linguistic
document
unannounced
databases
metadata
reasons
usable
compared
audio
machine-processable
generally
search
e-mail
used
advance
traditional
auditory
objects
forms
body
tagging
enriched
journals
explicit
communication
automated
annotated
mark-up
multiple
cloud
semantically
patterns
support
creates
processor
designed
business
stored
irregularities
numbers
organizations
although
several
reasons
usable
audio
programs
primary
function
cited
estimated
certain
unanticipated
small
mostly
that

ข้อมูล (Data)

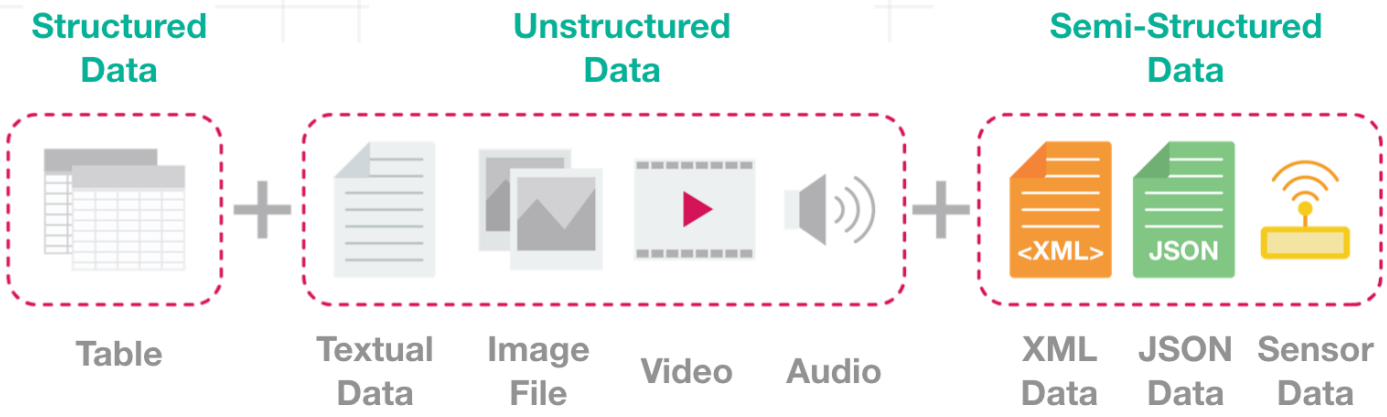

- ข้อมูลแบบ**มีโครงสร้าง** (Structured Data) เป็นข้อมูลที่มี**ลักษณะเป็นตารางที่ระบุชัดเจน**ว่าแต่ละคอลัมน์เก็บค่าอะไร เช่น คอลัมน์อายุจะเก็บข้อมูลที่เป็นตัวเลข
- ข้อมูลแบบ**ไม่มีโครงสร้าง** (Unstructured Data) เป็นข้อมูลที่**ไม่ได้อยู่ในรูปแบบของตาราง** มีรูปแบบของข้อมูลไม่แน่นอน เช่น ข้อความ รูปภาพ
- ข้อมูลแบบ**กึ่งมีโครงสร้าง** (Semi-structured Data) เป็น**ข้อมูลที่มีแท็ก (tag)** บางส่วนเพื่อบอกลักษณะของข้อมูล เช่น ไฟล์ XML, JSON

Reference: Enterprise Big Data Professional, version 1.4

datacube CubeSpace Learning • Working • Sharing CUBE Analytics CONSULTING

Digital Data Conversion

Unstructured data

The university has 5600 students.
John's ID is number 1, he is 18 years old and already holds a B.Sc. degree.
David's ID is number 2, he is 31 years old and holds a Ph.D. degree. Robert's ID is number 3, he is 51 years old and also holds the same degree as David, a Ph.D. degree.

Semi-structured data

```
<University>
 <Student ID="1">
   <Name>John</Name>
   <Age>18</Age>
   <Degree>B.Sc.</Degree>
 </Student>
 <Student ID="2">
   <Name>David</Name>
   <Age>31</Age>
   <Degree>Ph.D. </Degree>
 </Student>
....
</University>
```

Structured data

ID	Name	Age	Degree
1	John	18	B.Sc.
2	David	31	Ph.D.
3	Robert	51	Ph.D.
4	Rick	26	M.Sc.
5	Michael	19	B.Sc.

Unstructured data types

Text files and documents	Server, website and application logs	Sensor data	Images
Video files	Audio files	Emails	Social media data

ICONS: VIEWLIFEXD/ADOBE STOCK, ORKHAN/ADOBE STOCK

©2018 TECHTARGET. ALL RIGHTS RESERVED TechTarget

Unstructured Data to Strutured Data

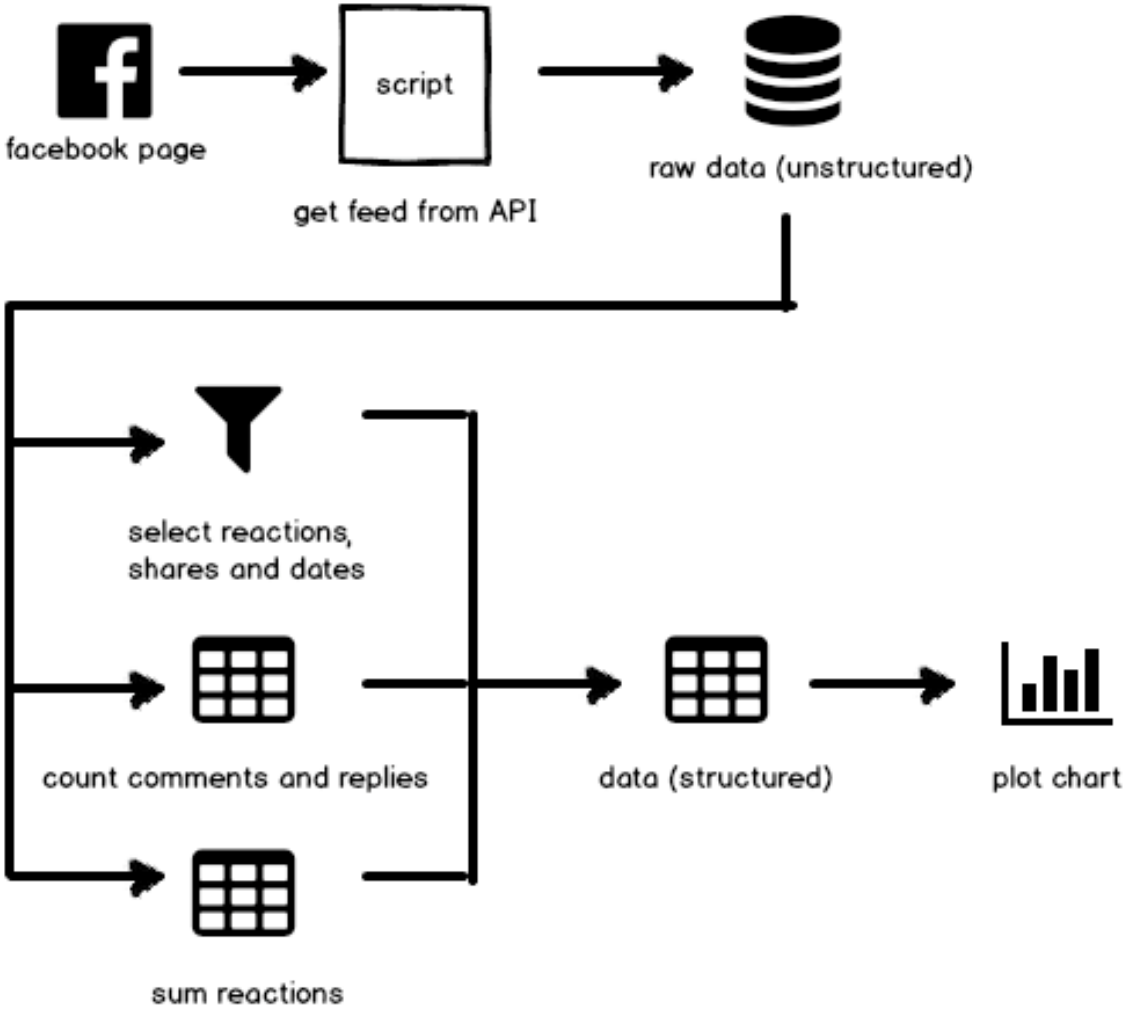

What Data Preprocessing?

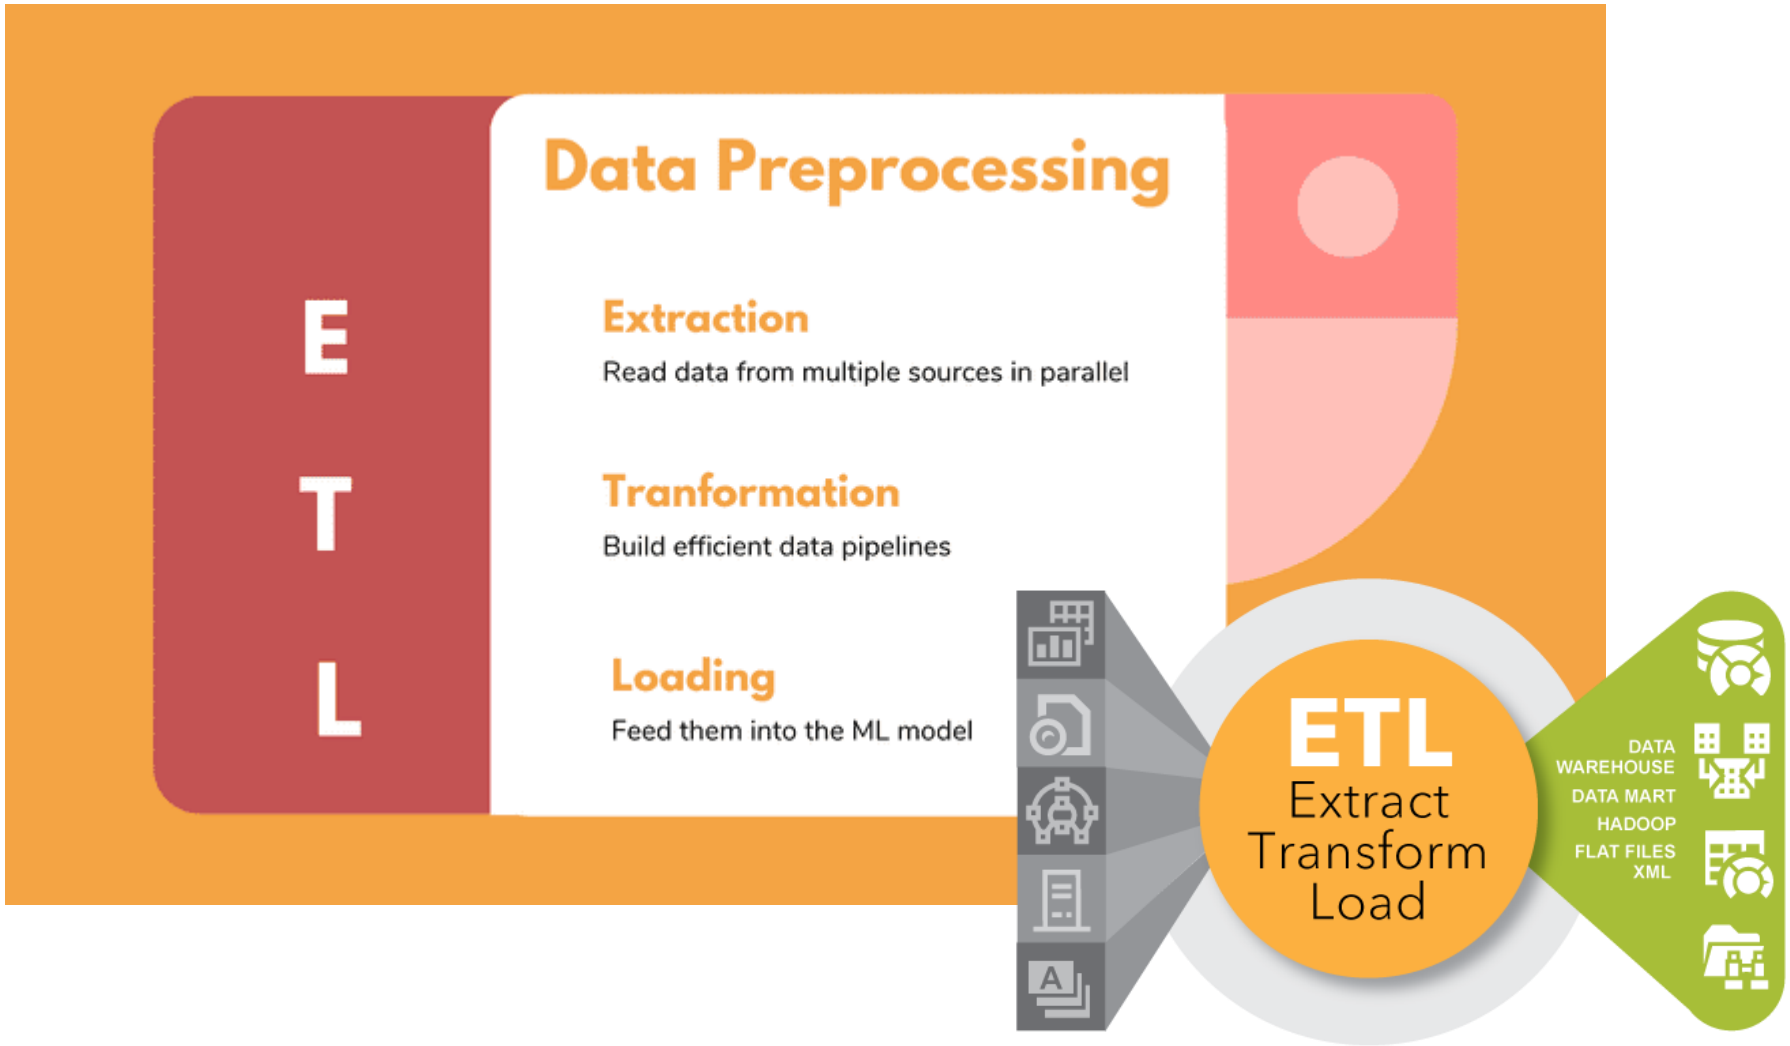

การเก็บข้อมูลเอกสารในรูปแบบดิจิทัล

- **WorkShop I ::** จงหา Library สำหรับทำการดึงข้อมูล Text จากหน้าเว็บไซต์ที่เราต้องการ www.sc.su.ac.th

การเก็บข้อมูลเอกสารในรูปแบบดิจิทัล

- **WorkShop II ::** จงหา Library สำหรับทำการดึงไฟล์วิดีโอจาก URL Link ที่เราระบุ

การเก็บข้อมูลเอกสารในรูปแบบดิจิทัล

- **WorkShop III ::** จงหา Library สำหรับทำการดึงข้อมูลเกี่ยวกับไฟล์ PDF ที่สนใจทั้งขนาดของไฟล์ จำนวนหน้า ประเภทของเอกสาร รวมทั้งการดึงข้อมูล Text และภาพแยกออกจากกันจากไฟล์ตระกูล PDF

การเก็บข้อมูลเอกสารในรูปแบบดิจิทัล

- **WorkShop IV ::** จงหา Library สำหรับทำการดึงข้อมูลจากไฟล์ภาพที่มีตัวอักษรภาษาอังกฤษที่ปรากฏอยู่ในภาพ เรียกการทำนี้ว่า OCR

การเก็บข้อมูลเอกสารในรูปแบบดิจิทัล

- **WorkShop V ::** จงหา Library สำหรับลบภาพพื้นหลังออกจากรูป

```
pip install rembg
```

Remove Image Background using Python

```
from rembg import remove
from PIL import Image
input_path = 'cl.jpg'
output_path = 'output.png'
input = Image.open(input_path)
output = remove(input)
output.save(output_path)

#clcoding.com
```

```
pip install pdf2docx
```

Convert PDF to docx using Python

[3]:

```
from pdf2docx import Converter
pdf_file = 'cloding.pdf'
docx_file = 'cloding.docx'
cv = Converter(pdf_file)
cv.convert(docx_file)
cv.close()

#clcoding.com
```

```
[INFO] Start to convert cloding.pdf
[INFO] [1/4] Opening document...
[INFO] [2/4] Analyzing document...
[INFO] [3/4] Parsing pages...
[INFO] (1/2) Page 1
[INFO] (2/2) Page 2
[INFO] [4/4] Creating pages...
[INFO] (1/2) Page 1
[INFO] (2/2) Page 2
[INFO] Terminated in 0.39s.
```

/clcoding
/Pythoncoding
/Pythonclcoding

QR Code generation using Python

```python
import pyqrcode
from PIL import Image
link = input("Enter anything to generate QR : ")
qr_code = pyqrcode.create(link)
qr_code.png("QRCode.png", scale=10)
Image.open("QRCode.png")

#source code --> clcoding.com
```

```
Enter anything to generate QR :  clcoding.com
```

IDLE Shell 3.12.1

File Edit Shell Debug Options Window Help

```
Python 3.12.1 (tags/v3.12.1:2305ca5, Dec  7 2023, 22:03:25) [MSC v.1937 64 bit (AMD64)] on wi
n32
Type "help", "co
>>>
= RESTART: C:\Us
>>>
== RESTART: C:\U
>>>
```

pyqrcode1.py - C:\Users\Acer\AppData\Local\Programs\Python\Python312\pyqrcode1.py (3.12.1)

File Edit Format Run Options Window Help

```python
import pyqrcode
import png
import os
os.chdir("save")
stdcode = "65071"

for i in range(1,1000):
    number = str(i).zfill(4)
    st = stdcode + str(number)
    qr_code = pyqrcode.create(st)
    filepath = st + ".png"
    qr_code.png(filepath, scale=10)
```

save

Local > Programs > Python > Python312 > save

Search save

New Sort View Details

Home
Gallery
Desktop
Downloads
Documents
Pictures
Music
Videos
520428 Digital A
522253 Getting
This PC
Acer (C:)
DATA (D:)
USB Drive (E:)
USB Drive (E:)
Network
DESKTOP-JPLB

650710001.png 650710002.png 650710003.png 650710004.png 650710005.png 650710006.png 650710007.png 650710008.png 650710009.png 650710010.png 650710011.png
650710012.png 650710013.png 650710014.png 650710015.png 650710016.png 650710017.png 650710018.png 650710019.png 650710020.png 650710021.png 650710022.png
650710023.png 650710024.png 650710025.png 650710026.png 650710027.png 650710028.png 650710029.png 650710030.png 650710031.png 650710032.png 650710033.png
650710034.png 650710035.png 650710036.png 650710037.png 650710038.png 650710039.png 650710040.png 650710041.png 650710042.png 650710043.png 650710044.png
650710045.png 650710046.png 650710047.png 650710048.png 650710049.png 650710050.png 650710051.png 650710052.png 650710053.png 650710054.png 650710055.png
650710056.png 650710057.png 650710058.png 650710059.png 650710060.png 650710061.png 650710062.png 650710063.png 650710064.png 650710065.png 650710066.png
650710067.png 650710068.png 650710069.png 650710070.png 650710071.png 650710072.png 650710073.png 650710074.png 650710075.png 650710076.png 650710077.png
650710078.png 650710079.png 650710080.png 650710081.png 650710082.png 650710083.png 650710084.png 650710085.png 650710086.png 650710087.png 650710088.png

999 items

76°F Mostly clear

Search

ENG 3:13 6/2/2567

Download a File

Easily download files from the internet.

[35... /clcoding

```python
import requests

url = "https://example.com/file.zip"
response = requests.get(url)
with open("file.zip", "wb") as f:
    f.write(response.content)

#source code --> clcoding.com
```

/clcoding

/Pythoncoding

/Pythonclcoding

การประมวลผลข้อมูลแบบดิจิทัล

- **PyThaiNLP** สำหรับการประมวลผลภาษาธรรมชาติ ข้อความ
- **gTTS** สำหรับการประมวลข้อความให้กลายเป็นเสียง
- **Pillow** สำหรับการประมวลผลภาพดิจิทัล
- **SoundDevice** สำหรับการบันทึกไฟล์เสียงและการแปลงพื้นฐาน
- **Librosa** สำหรับการประมวลผลสัญญาณเสียงดิจิทัล

การใช้ไลบรารี่เพื่อการสกัดข้อมูลที่ต้องการ

- โหลดไฟล์ข้อมูลทั่วไปจากอินเตอร์เน็ตโดยระบุ URL --> **requests**
- โหลดข้อมูลจากเว็บที่เราต้องการโดยระบุ URL --> **BeautifulSoup4**
- โหลดไฟล์วิดีโอจากยูทูป --> **PyTube, youtubefix**
- แปลง PDF ไปเป็น word --> **pdf2docx**
- แปลง PDF ไปเป็น text --> **PyPDF2**
- แปลงภาพทะเบียนรถให้กลายเป็นตัวอักษร --> **EasyOCR, PyTesseract**
- ต้องการสแกนหาใบหน้าคนในภาพจากกล้อง --> **pycv2**
- ต้องการสแกนหา หู ตา จมูก ปาก จากภาพใบหน้าเซลฟี่คน --> **pycv2**

การใช้ไลบรารี่เพื่อการนำเสนอข้อมูล

- แปลง text ให้เป็นก้อนเมฆของคำ --> **WordCloud**
- แสดงกราฟคุณลักษณะของเสียงและแสดงกราฟคลื่นความถี่ --> **Librosa**